

Рубежный контроль №1

Тема: Технологии разведочного анализа и обработки данных.

Исполнитель: Мефодьев Илья Николаевич, группа ИУ5Ц-82Б

Вариант: 28; Номер задачи: 4; Номер набора данных: 4;

Для студентов групп ИУ5-62Б, ИУ5Ц-82Б - для произвольной колонки данных построить гистограмму

Задача №4

Для заданного набора данных постройте основные графики, входящие в этап разведочного анализа данных. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Какие графики Вы построили и почему? Какие выводы о наборе данных Вы можете сделать на основании построенных графиков?

Ход выполнения

Работаю с датасетом **Heart Disease Dataset** -

<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Этот набор данных датируется 1988 годом и состоит из четырех баз данных в клиниках: Кливленд, Венгрия, Швейцария и Лонг-Бич V. Он содержит 76 атрибутов, включая прогнозируемый атрибут, но во всех опубликованных экспериментах упоминается использование подмножества из 14 из них.

Поле «цель» указывает на наличие сердечного заболевания у пациента.

Оно имеет целочисленное значение: 0 = отсутствие заболевания и 1 = наличие заболевания.

В датасете следующие поля:

1. **age** - Возраст пациента

2. **sex** - Пол пациента (1 = male; 0 = female)
3. **CP = chest pain type (4 values)** - Тип боли в груди
4. **trestbps = resting blood pressure** - Артериальное давление в состоянии покоя (в мм рт. ст. при поступлении в больницу)
5. **chol = serum cholestoral in mg/dl** - уровень холестерина в сыворотке крови (мг/дл)
6. **fbs = fasting blood sugar > 120 mg/dl** - Уровень сахара в крови натощак > 120 мг/дл (1 = верно; 0 = неверно)
7. **restecg = resting electrocardiographic results (values 0,1,2)** - результаты электрокардиографии в состоянии покоя
8. **thalach = maximum heart rate achieved** - максимальная частота сердечных сокращений
9. **exang = exercise induced angina** - стенокардия, вызванная физической нагрузкой
10. **oldpeak = ST depression induced by exercise relative to rest** - Снижение сегмента ST, вызванное физической нагрузкой, по сравнению с состоянием покоя
11. **slope = the slope of the peak exercise ST segment** - наклон пикового сегмента ST во время физической нагрузки
12. **ca = number of major vessels (0-3) colored by flourosopy** - количество крупных сосудов (0-3), окрашенных с помощью флюороскопии
13. **thal: 0 = normal; 1 = fixed defect; 2 = reversable defect** - таламус: 0 = норма; 1 = фиксированный дефект; 2 = обратимый дефект
14. **target** - Поле «цель» указывает на наличие сердечного заболевания у пациента. 1 или 0

Первым делом импортируем необходимые библиотеки и выведем первые 10 элементов датасета

```
# добавим необходимые модули
```

```
import pandas as pd
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
HEART_ORIGIN = pd.read_csv("./heart.csv")
```

```
HEART_ORIGIN.head(10)
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	52	1	0	125	212	0	1	168	0	1.0	2	2	3	0
1	53	1	0	140	203	1	0	155	1	3.1	0	0	3	0
2	70	1	0	145	174	0	1	125	1	2.6	0	0	3	0
3	61	1	0	148	203	0	1	161	0	0.0	2	1	3	0
4	62	0	0	138	294	1	1	106	0	1.9	1	3	2	0
5	58	0	0	100	248	0	0	122	0	1.0	1	0	2	1
6	58	1	0	114	318	0	2	140	0	4.4	0	3	1	0
7	55	1	0	160	289	0	0	145	1	0.8	1	1	3	0
8	46	1	0	120	249	0	0	144	0	0.8	2	0	3	0
9	54	1	0	122	286	0	0	116	1	3.2	1	2	2	0

Для начала посмотрим на ситуацию с пропусками

```
print('Всего строк: {}'.format(HEART_ORIGIN.shape[0]))
```

```
print(f"\nВсего пропусков: {HEART_ORIGIN.isnull().sum().sum()}")
```

```
for i in list(HEART_ORIGIN.columns):
```

```
print(i + "\t" + str(HEART_ORIGIN[i].isnull().sum()) + "\t" +
```

```
str(round(HEART_ORIGIN[i].isnull().mean()*100, 2)) + "%")
```

Всего строк: 1025


Всего пропусков: 0

age	0	0.0%
sex	0	0.0%
cp	0	0.0%
trestbps	0	0.0%
chol	0	0.0%
fbs	0	0.0%
restecg	0	0.0%
thalach	0	0.0%
exang	0	0.0%
oldpeak	0	0.0%
slope	0	0.0%
ca	0	0.0%
thal	0	0.0%
target	0	0.0%

Отличные новости! Пропусков нету, следовательно, не нужно с ними работать

Дальше сразу построим гистограмму возрастов пациентов


```
plt.figure(figsize=(6, 4))
sns.histplot(data=HEART_ORIGIN, x='age', bins=20, kde=True,
color='skyblue')
plt.title('Распределение возраста пациентов')
plt.xlabel('Возраст')
plt.ylabel('Частота')
plt.show()
```



На гистограмме видно, что большинство пациентов прибывает в возрасте 60 лет. Также есть скачок в группе сорокалетних.

Далее построим корреляционную тепловую карту

```
plt.figure(figsize=(10, 8))
sns.heatmap(HEART_ORIGIN.corr(), annot=True, cmap='coolwarm', fmt='.2f',
linewidths=0.5)
plt.title('Корреляционная матрица признаков')
plt.show()
```




Сильных корреляций не найдено, хотя обратных корреляций немало. В глаза бросается обратная корреляция между наклоном и падением ST (не могу сказать, что именно означает этот медицинский термин)

Далее посмотрим на распределение целевой переменной - есть ли у пациента сердечное заболевание?

```
plt.figure(figsize=(5, 4))
sns.countplot(data=HEART_ORIGIN, x='target', palette='pastel')
```

```
plt.title('Баланс классов: наличие сердечного заболевания (0 - нет, 1 -  
есть)')  
plt.xlabel('target')  
plt.ylabel('Количество записей')  
plt.show()
```




Видно, что пропорция почти равная, что неудивительно, учитывая места сбора статистики. Например, в армейской казарме статистика была бы куда сильнее выражена в пользу здоровых людей

Далее посмотрим, например, максимальную ЧСС для людей с сердечными заболеваниями и без него

```
plt.figure(figsize=(6, 5))  
sns.boxplot(data=HEART_ORIGIN, x='target', y='thalach', palette='Set2')  
plt.title('Максимальная ЧСС в зависимости от наличия сердечного  
заболевания')  
plt.xlabel('target (0 - здоров, 1 - болен)')  
plt.ylabel('thalach (макс. ЧСС)')  
plt.show()
```

Максимальная ЧСС в зависимости от наличия сердечного заболевания



Результат ожидаемый - у "сердечников" ЧСС оказалась выше, чем у людей без сердечных заболеваний

Построенные графики и обоснование выбора

1. **Гистограмма `age`** — для анализа распределения возрастного состава выборки.
2. **Тепловая карта корреляций** — поиск корреляций между признаками.
3. **Столбчатая диаграмма `target`** — проверка баланса классов.
4. **Boxplot `thalach` по `target`** — визуальное сравнение показателя у пациентов с болезнью и без.

Выводы по набору данных

- Пропусков в данных нет, объём выборки: 1025 записей.
- Распределение возраста близко к нормальному с лёгким смещением, присутствует небольшой скачок в группе сорокалетних.
- Классы `target` слегка несбалансированы, но на статистику это не влияет.
- Наибольшую отрицательную корреляцию с наличием болезни имеют `exang` и `oldpeak` (оба $\sim -0,44$), положительную — `cp` ($\sim 0,43$).
- У пациентов с сердечным заболеванием медианная максимальная ЧСС статистически выше, а разброс значений меньше.

- - Набор данных чист, признаков достаточно для построения бинарного классификатора. Рекомендуется перед моделированием выполнить масштабирование числовых признаков.